


Chunking Module

1. Mô tả vấn đề


dataset test:

.md: https://drive.google.com/file/d/1BdijhGPkK2U2Nzjxn4D_rx_M8SKJOHlp/view?usp=drive_link

.pdf: https://drive.google.com/file/d/1tAyuVdNDS5S3cQLagq4TU4N7A7iX6_Tn/view?usp=sharing



Chunking fixed-size
1200 token



Problem

Chunk cắt vị trí chưa đẹp

Các chunk thiếu ngữ cảnh toàn cục

```
"doc-4bf256e3d66747873f36812366ac0ae1-chunk-002": {
  "tokens": 761
  "content": "# 7.1 KIẾN THỨC GIÁO DỤC ĐẠI CƯƠNG\nTổng cộng 63 tín chỉ (phòng kế Giáo dục thể chất và Giáo dục quốc phòng), bao gồm các khối kiến thức Tin học, Toán, Vật lý, Khoa học xã hội và nhân văn\n7.1.1. Kiến thức Tin học\n<table border='1' class='table'>\n<thead>\n<tr style='text-align: right;'>\n<th>STT</th>\n<th>MÃ SỐ</th>\n<th>TÊN HỌC PHẦN</th>\n<th>TC</th>\n<th>LT</th>\n<th>TH</th>\n<th>Loại</th>\n</tr>\n</thead>\n<tbody>\n<tr>\n<td>1</td>\n<td>CTT003</td>\n<td>Nhập môn lập trình</td>\n<td>4</td>\n<td>45</td>\n<td>30</td>\n<td>BB</td>\n</tr>\n<tr>\n<td>2</td>\n<td>CTT005</td>\n<td>Lý thuyết đồ thị</td>\n<td>4</td>\n<td>45</td>\n<td>30</td>\n<td>BB</td>\n</tr>\n<tr>\n<td>3</td>\n<td>CTT006</td>\n<td>Phương pháp lập trình hướng đối tượng</td>\n<td>4</td>\n<td>45</td>\n<td>30</td>\n<td>BB</td>\n</tr>\n<tr>\n<td>4</td>\n<td>CTT008</td>\n<td>Kỹ thuật lập trình</td>\n<td>4</td>\n<td>45</td>\n<td>30</td>\n<td>BB</td>\n</tr>\n<tr>\n<td>5</td>\n<td>CTT009</td>\n<td>Nhập môn Công nghệ thông tin 1</td>\n<td>3</td>\n<td>30</td>\n<td>45</td>\n<td>BB</td>\n</tr>\n<tr>\n<td>6</td>\n<td>CTT010</td>\n<td>Nhập môn Công nghệ thông tin 2</td>\n<td>3</td>\n<td>30</td>\n<td>45</td>\n<td>BB</td>\n</tr>\n<tr>\n<td>7</td>\n<td>CTT011</td>\n<td>Nhập môn VHDN NB</td>\n<td>2</td>\n<td>20</td>\n<td>30</td>\n<td>BB</td>\n</tr>\n</tbody>\n</table>\n7.1.2. Kiến thức Toán",
  "chunk_order_index": 2,
  "full_doc_id": "doc-4bf256e3d66747873f36812366ac0ae1",
  "file_path": "pdf_test.md",
  "lm_cache_list": [
```

Thiếu ngữ cảnh tổng quan
-> Kiến thức giáo dục đại
cương của chương trình
nào?

2. Mô tả Solution

Dạ chúng em tham khảo ý tưởng ở paper Multidoc Fusion (Hội nghị EMNLP A*): <https://aclanthology.org/2025.emnlp-main.1062/>




Figure 1: The pipeline for **MultiDocFusion**. The figure illustrates the step-by-step process for handling a long industrial document. (a) DP extracts layout structures; (b) OCR recognizes and annotates text; (c) DSHP-LLM constructs a hierarchical tree from identified section headers and general nodes; (d) DFS-based Grouping constructs

```
# CHƯƠNG TRÌNH ĐÀO TẠO
NGÀNH KỸ THUẬT PHẦN MỀM
Khóa tuyển: 2024

(Ban hành kèm theo Quyết định số \underline{2493/0A-14HTN}\$ ngày \underline{18/9/2024}\$
của Hiệu trưởng Trường Đại học Khoa học Tự nhiên, \mathcal{D}HQG-HCM\$ )

## 1. THÔNG TIN CHUNG VỀ CHƯƠNG TRÌNH ĐÀO TẠO
1.1. Tên ngành đào tạo:
    \- Tiếng Việt : Kỹ thuật phần mềm
    \- Tiếng Anh : Software Engineering
1.2. Mã ngành đào tạo : 7480103
1.3. Trình độ đào tạo : Đại học
1.4. Tên chương trình : Cử nhân Kỹ thuật phần mềm
1.5. Hình thức đào tạo : Chính quy
1.6. Thời gian đào tạo : 4 năm
1.7. Tên văn bằng sau khi tốt nghiệp:
    \- Tiếng Việt : Cử nhân Kỹ thuật phần mềm
    \- Tiếng Anh : Bachelor of Science in Software Engineering
1.8. Ngôn ngữ giảng dạy : tiếng Việt
1.9. Nội đào tạo:
    \- Cơ sở 1 : 227 Nguyễn Văn Cù, P4, Q5, Tp.HCM
```

```
[section_chunking] —— Chunk #4 ——
depth : 2
path : 2.1
parent : 2
tokens : 372
hierarchy: ## 2. MỤC TIÊU ĐÀO TẠO > ### 2.1. MỤC TIÊU CHUNG
content : |
## 2. MỤC TIÊU ĐÀO TẠO > ### 2.1. MỤC TIÊU CHUNG > Chương trình đào tạo Cử nhân Hệ thống thông tin hướng đến việc hình thành đội ngũ chuyên gia có
- Có khả năng thiết kế, triển khai, quản trị và khai thác hệ thống thông tin phục vụ hoạt động quản lý, ra quyết định và đối mối trong các tổ chức
- Được trang bị kiến thức nền tảng vững chắc về công nghệ thông tin, cơ sở dữ liệu, phân tích và thiết kế hệ thống, khai thác, phân tích dữ liệu
- Có tư duy phân tích, tư duy hệ thống và tư duy tổ chức, giúp nhận diện, mô hình hóa và cải tiến quy trình nghiệp vụ thông qua các giải pháp công nghệ
- Có năng lực phân tích, tư duy hệ thống và tư duy tổ chức, giúp họ có thể nhận biết, mô hình hóa và cải tiến quy trình hoạt động thông qua các g
```

```

58 | - Sơ hữu kế năng giao tiếp, giải quyết vấn đề, làm việc nhóm, quản lý dự án và học tập suốt đời, cũng đào đức nghề nghiệp và tinh thần trách nhiệm
59 |
60 | [section chunking] ----- Chunk #5 -----
61 | depth : 2
62 | path : 2.2
63 | parent : 2
64 | tokens : 398
65 | hierarchy: ## 2. MỤC TIÊU ĐÀO TẠO > ### 2.2. MỤC TIÊU CỤ THỂ
66 | content : |
67 | ## 2. MỤC TIÊU ĐÀO TẠO > ### 2.2. MỤC TIÊU CỤ THỂ > | Ký hiệu mục tiêu | Nội dung |
68 | --- | --- |
69 | | P01 | Nhận thức được vai trò, trách nhiệm và đạo đức nghề nghiệp của người làm trong lĩnh vực hệ thống thông tin; hiểu rõ tác động của công nghệ
70 | | P02 | Có kỹ năng tư duy phân tích, tư duy hệ thống, kỹ năng giao tiếp và làm việc nhóm, giúp người học có khả năng hợp tác hiệu quả với các chủ
71 | | P03 | Có khả năng tự học, cập nhật và phát triển kiến thức chuyên môn, sẵn sàng thích ứng với các công nghệ mới, quy trình mới và yêu cầu thay
72 | | P04 | Có khả năng vận dụng kiến thức nền tảng về công nghệ thông tin, cơ sở dữ liệu, phân tích nghiệp vụ và mô hình hóa quy trình để xác định,
73 | | P05 | Có khả năng phân tích, xây dựng, triển khai và quản trị các hệ thống thông tin phục vụ cho quản lý, ra quyết định, khai thác dữ liệu và
74 | | P06 | Có khả năng sử dụng hiệu quả các công cụ, kỹ thuật và phương pháp hiện đại trong phát triển, đánh giá, kiểm thử và bảo mật hệ thống thông

```

Mỗi chunk lưu đoạn văn cùng với đường dẫn header (header injection)

Khi chunk dài, cắt theo chunk_size, chunk tiếp theo vẫn giữ đường dẫn header injection

Embed với token_size 512

Hiện tại tui em đang dùng model này để embedding mà model này tác giả recommend là 512 token
Link tham khảo: <https://huggingface.co/intfloat/multilingual-e5-large-instruct>

3. Benchmark khi áp dụng Solution

Dạ cách evaluation tui em tham khảo paper RAGAS: Automated Evaluation of Retrieval Augmented Generation (ACL A*)
link: <https://aclanthology.org/2024.eacl-demo.16/>

```

INFO: =====
/Downloads/LightRAG-main/lightrag/evaluation/eval_rag_quality.py
INFO: =====
INFO: Average Faithfulness: 0.7579
INFO: Average Answer Relevance: 0.3606
INFO: Average Context Recall: 1.0000
INFO: Average Context Precision: 0.7583
INFO: Average RAGAS Score: 0.7192
INFO:
INFO: Min RAGAS Score: 0.4583
INFO: Max RAGAS Score: 0.8762
INFO:
INFO: =====
INFO: GENERATED FILES
INFO: =====
INFO: Results Dir: /Users/nhattanlht/Downloads/LightRAG-main/lightrag/evaluation/results
INFO:   CSV: results_20260606_094627.csv
INFO:   JSON: results_20260606_094627.json
INFO: =====

```

Chưa áp dụng solution

```

=====
KẾT QUẢ ĐÁNH GIÁ
=====
Metric                               Score
-----
Faithfulness (độ trung thực)         0.7771

```

Áp dụng solution


Answer Relevance (độ liên quan)	0.9500
Context Relevance (chính xác retrieve)	0.8625


Average (tổng hợp)	0.8632

Kết luận:

- Ưu: tăng được hiệu quả khi truy xuất
- Nhược: Còn phụ thuộc vào upstream là parser (Layout Analysis)

Query mix mode





1. Full text search

```

# Tập dữ liệu mẫu (Documents)
documents = {
  1: "Elasticsearch is a distributed, RESTful search and analytics engine.",
  2: "Full-text search involves text analysis and inverted index creation.",
  3: "Relevance scoring in Elasticsearch uses the Okapi BM25 algorithm by default.",
  4: "An inverted index maps each token to the documents that contain it."
}

```

```

# Thử nghiệm các truy vấn
full_text_search("search index")
full_text_search("BM25 algorithm for relevance scoring")

```

Source documents


Search query

- Reducing a query term to the root form of a word.
- Removing non-essential words (stopwords, such as "the" or "and" in English).

Analysis pipeline

- Breaking a composite word into component parts.
- Lowercasing an uppercase word.

1. KẾT QUẢ TEXT ANALYSIS (Document 2):
 Gốc: Full-text search involves text analysis and inverted index creation.
 Tokens: ['fulltext', 'search', 'involves', 'text', 'analysis', 'inverted', 'index', 'creation']



2. INVERTED INDEX CREATION (Trích xuất từ từ 'search' và 'index'):
 Từ 'search' xuất hiện trong các Document IDs: [1, 2]
 Từ 'index' xuất hiện trong các Document IDs: [2, 4]

--- TRUY VẤN: 'search index' ---
 Query Tokens: ['search', 'index']
 Raw BM25 Scores: [0. 0. 0. 0.]

--- TRUY VẤN: 'BM25 algorithm for relevance scoring' ---
 Query Tokens: ['bm25', 'algorithm', 'relevance', 'scoring']
 Raw BM25 Scores: [0. 0. 3.18447518 0.]
 [Score: 3.1845] Document 3: Relevance scoring in Elasticsearch uses the Okapi BM25 algorithm by default.

$$Score(q, d) = \sum_{t \in q} IDF(t) \cdot TF(t, d)$$

$$TF(t, d) = \frac{freq(t, d)}{freq(t, d) + k_1 \cdot (1 - b + b \cdot \frac{|d|}{avgdl})}$$

where:

- t : Query term
- d : Document
- $freq(t, d)$: Number of times term t appears in document d
- $|d|$: Length of document d
- $avgdl$: average document length in corpus
- k_1 : controls term frequency scaling
- b : controls document length normalization

$$IDF(t) = \log\left(\frac{N - n_t + 0.5}{n_t + 0.5}\right)$$



where:

- N : Total number of documents in the corpus
- n_t : Number of documents containing term t

2. Vector Search

Dense vector

Sử dụng thuật toán **k-Nearest Neighbor (kNN)** để tìm kiếm các vector giống nhau. Thay vì khớp từ khóa chính xác (keyword match), kNN tìm kiếm dựa trên ý nghĩa ngữ nghĩa




Bảng tham khảo: <https://www.geeksforgeeks.org/nlp/what-is-bm25-best-matching-25-algorithm/>

3. Multimodal search

Tìm kiếm đa phương thức đề cập đến khả năng tiếp nhận, hiểu và truy xuất thông tin trên nhiều loại nội dung khác nhau, bao gồm văn bản, hình ảnh, video và âm thanh.

Quy trình hoạt động (Multimodal Pipeline):




Building a robust multimodal pipeline typically involves:

1. Extracting inline images and page text from documents.
2. Describing images in natural language.
3. Embedding both text and images into a shared vector space.
4. Storing the images for later use as annotations.

Markdown file


4. Hybrid vector search



$$RRFscore(d \in D) = \sum_{r \in R} \frac{1}{k + r(d)},$$

Nguồn tham khảo: <https://dl.acm.org/doi/epdf/10.1145/1571941.1572114>

5. Graph Traversal



4. Traversal KG + Hybrid vector search

